

*Parkinson Hastalığının Teşhisi*

# VGG16 YARDIMIYLA LOJİSTİK REGRESYON İLE SİRAL GÖRÜNTÜLERİNDEN PARKINSON HASTALIĞI TEŞHİSİ

Sefer Enes Erdemoğlu

11 Ocak 2026

## İÇİNDEKİLER

<b>1 Giriş ve Araştırma Motivasyonu</b>	<b>3</b>
<b>2 Süreç</b>	<b>3</b>
<b>3 Veri Seti ve Ön İşleme Katmanı</b>	<b>4</b>
3.1 Kinematik Veriler (Ham Dijitalleştirme) . . . . .	4
3.2 Görsel Veriler (Spiral Çizimleri) . . . . .	4
<b>4 Metodoloji ve Özellik Mühendisliği</b>	<b>5</b>
4.1 Geleneksel (Hand-crafted) Özellikler . . . . .	5
4.2 Derin Görsel Özellikler (Transfer Learning) . . . . .	5
<b>5 Deneysel Sonuçlar ve Performans Analizi</b>	<b>6</b>
5.1 Model Karşılaştırmaları (ML Aşaması) . . . . .	6
5.2 Derin Öğrenme ve Stabilitate Testi Sonuçları . . . . .	6
5.3 Boyut İndirgeme ve PCA Etkisi . . . . .	7
<b>6 Tartışma: Neden Bazı Modeller Daha Üstün?</b>	<b>7</b>
6.1 Random Forest'ın K-NN Üzerindeki Üstünlüğü . . . . .	7
6.2 Derin Öğrenmenin (%85.7) Geleneksel Yöntemden (%75.8) Farkı . . . . .	7
<b>7 SOTA ile Karşılaştırma</b>	<b>8</b>
<b>8 Sonuç, Kazanımlar ve Gelecek Çalışmalar</b>	<b>8</b>

## GİRİŞ VE ARAŞTIRMA MOTİVASYONU

Parkinson hastalığının zamanında tespitini, hızlı tedaviyi kolaylaştırır ve [Sino7]'de bildirildiği gibi semptomları önemli ölçüde hafifletir, hastanın kalan ömrünü nispeten rahat yaşamasını sağlar. Aynı zamanda erken teşhis, hastalık masraflarını üstlenen ülkelerin kamu bütçesi üzerindeki ekonomik baskıyı azaltır.

Günümüzde sağlık alanında makine öğrenmesi ve derin öğrenme uygulamaları revaçta olduğu için Parkinson hastalığı, özellikle son 2-3 yıldır aktif olarak çalışılmaktadır. Teşhis için birçok yöntem olsa da çoğu ulaşılması maliyetli ve klinik ortam gerektiren yöntemlerdir.

Sağlık gibi temel bir konuda eşit erişim ve demokratikleşme için bu çalışmada mümkün olabilecek en sade yöntemlerle teşhis yapmak arzulanmaktadır. Bunun için kullanıcıdan sadece kağıt üstüne bir Arşimet spirali çizmesi istenmektedir. Spiralin fotoğraflayıp diğer projenin çıktısı olan web-app'e yükleyen kullanıcı, Parkinson hastalığı riski taşıyıp taşımadığını görebilir. Bu projenin konusu, bahsi geçen diğer proje (web-app) için makine öğrenmesi modeli oluşturmaktır.

Bu rapor, PaHaW [BDA24](Parkinson's Disease Handwriting Database) ve Spiral Dataset [Madı8] veri setleri kullanılarak Parkinson hastalığının yapay zeka ile teşhisi üzerine yürütülen çok aşamalı araştırma ve geliştirme sürecini dokümanite etmektedir.

Çalışmanın amacı, proje dersi kapsamında geleneksel makine öğrenmesi metotlarını öğrenmek, makine görüşü konusunun temellerini içselleştirmek ve ileride bu konuda gerçekleştirilecek projelere temel oluşturmaktır.

## SÜREÇ

Çalışma önce literatür taramasıyla başlamış ve ardından geleneksel makine öğrenmesi metotlarının öğrenmesine geçilmiştir. Literatür taramalarında makine öğrenmesi ve bilgisayar görüşü konularında bilgi eksikliği, jargona ve terimlere uzaklık tespit edilmiş ve yoğun bir araştırma sürecine girilmiştir. Bu süreç devam ederken YÖK'ün verdiği "Veri Analizi Okulu" kursunun da temel istatistik ve Excel dersleri veri okuryazarlığı, veri işleme ve veriyi etkili kullanma konusunda yardımcı olmuştur.

Çalışmaya önce PaHaW veri seti ile başlanmış ve 5 makine öğrenmesi metoduyla %64 - %76 arasında doğruluk oranlarına ulaşılmıştır. Ama burada kullanılabilecek veri setinin yapısından dolayı bu işlem görüntü işlemeden daha çok veri analizi olarak nitelendirilebilir, çünkü PaHaW veri seti, spiral görsellerini değil; spiralleri çizerken dijital kalemle alınan verileri içermektedir. Diğer proje ödevinin konusu, bu projede geliştirilecek makine öğrenmesi modelini kullanan bir web-app tasarlamak olduğu için ve kullanıcıdan spiral görüntüsü (fotoğrafi) alarak bu yorumu yapacağımız için ve aynı zamanda ulaşılan doğruluk oranları düşük olduğu için

başka yöntemler arayışına girilmiş ve araştırma derinleştirilmiştir. İlk olarak makaleler tekrar taranmış ve daha önce makine öğrenmesi ile uğraşan arkadaşlarla istişare edilmiştir. Bunun sonucunda "Transfer Learning" yönteminin özellikle küçük veri setlerinde mucizeler yarattığı duyulmuş ve araştırmaya başlanmıştır. En çok kullanılan CNN modellerinden biri olan VGG16 bunun için seçilmiş ve ardından spiral görüntüleri aranarak Kaggle'da bulunmuştur. Bulunan bu veri setinden VGG16 ile özellik çıkarımı yapılmış ve bunun sonucunda 25.088 özellik bulunmuş ve % 85.71 doğruluk oranına erişilmiştir. Son olarak makaleler tekrar gözden geçirilince modellerin daha hızlı çalışması için en çok etkiyi yapan özelliklerin kullanılıp diğerlerinin elendiği görülmüş ve PCA (Principal Component Analysis) uygulanınca karar vermede %95 ağırlığa sahip 86 özellik olduğu saptanmıştır. Bir diğer deyişle bu 86 özellik, 25088 özelliğin özeti mahiyetindedir. Bu parametre azaltma sonucu model daha hızlı çalışmaya başlamış ve doğruluğu yaklaşık %1 artarak %86.67'ye ulaşmıştır. Ne var ki bu yeni model kullanıldığında hatanın görünenden çok daha büyük olduğu tespit edilerek diğer proje ödevi olan web-app'e entegre edilmemiştir.

### VERİ SETİ VE ÖN İŞLEME KATMANI

Çalışmada kullanılan veriler iki ana kaynaktan oluşmaktadır:


#### 3.1 KINEMATİK VERİLER (HAM DİJİTALLEŞTİRME)

PaHaW veri setinden [Sino7] alınan .svc uzantılı dosyalar, hastaların çizim anındaki;


- **X ve Y Koordinatları:** Hareketin geometrik yolu.
- **Zaman Damgası:** Çizim hızı ve ivmelenme [PK25].
- **Basınç (Pressure):** Motor kontrolün stabilitesi.
- **Azimut ve İrtifa:** Kalemın tutuş açısı gibi kritik 7 parametreyi içermektedir.

#### 3.2 GÖRSEL VERİLER (SİRAL ÇİZİMLERİ)

Statik görüntüler, hastaların Arşimet spirali çizimlerini içerir. Bu çalışmada kullanılan 102 adet görsel **Spiral Dataset** [BDA24] kaynağından temin edilmiştir. Bu görüntüler /healthy ve /parkinson klasörleri altında yapılandırılmış, model eğitimi öncesinde standart boyutlara (VGG16 girişi için uygun) getirilmiş ve piksel normalizasyonuna tabi tutulmuştur [Dro22].



(a) Sağlıklı bireye ait



(b) Hasta bireye ait

Şekil 1: Arşimet spirali görüntüleri

4

## METODOLOJİ VE ÖZELLİK MÜHENDİSLİĞİ

Proje, iki farklı özellik çıkarma (feature extraction) stratejisini karşılaştırmalı olarak incelemiştir:

### 4.1 GELENEKSEL (HAND-CRAFTED) ÖZELLİKLER

Kinematik verilerden türetilen 65 adet sayısal özellik (hız, ivme, sarsıntı, kalem kaldırma sayıları vb.) kullanılmıştır. Bu aşamada modeller, verinin ham halinden ziyade bu istatistiksel özetler üzerinden eğitilmiştir.

### 4.2 DERİN GÖRSEL ÖZELLİKLER (TRANSFER LEARNING)

Görüntü tabanlı analizde, sıfırdan bir CNN eğitmek yerine, ImageNet (14 milyondan fazla görüntü içeren bir görsel veri tabanı) üzerinde önceden eğitilmiş VGG16 mimarisi kullanılmıştır.

- **Derinlik:** Modelin son katmanları dondurularak görüntüden 25.088 adet yüksek boyutlu özellik (deep features) çıkarılmıştır.
- **Avantaj:** Bu yöntem, insan gözünün veya manuel istatistiklerin yakalayamayacağı karmaşık dokusal bozulmaları tespit etme kapasitesine sahiptir.

## DENEYSEL SONUÇLAR VE PERFORMANS ANALIZI


### 5.1 MODEL KARŞILAŞTIRMALARI (ML AŞAMASI)

Algoritma	Doğruluk (Accuracy)	Temel Gözlem
Gradient Boosting	%75.8	En yüksek başarıyı sağlayan geleneksel model.
Random Forest	%73.2	Kararlı ve gürültüye dayanıklı performans.
K-NN	%68.4	Mesafe tabanlı olduğu için yüksek boyutta zayıf kaldı.
SVM	%67.5	Titreme ayrıştırmada kısıtlı.
Logistic Regression	%64.2	Doğrusal olmayan ilişkileri yakalayamadı.

### 5.2 DERİN ÖĞRENME VE STABİLİTE TESTİ SONUÇLARI

VGG16'dan çıkarılan özellikler, sırasıyla yukarıda kullanılan makine öğrenmesi metotlarıyla eğitilmiş ve en yüksek doğruluk, lojistik regresyon yöntemiyle %90.48 doğruluk oranıyla sağlanmıştır. Test sonucunun güvenilir olması için test kümesi içinden farklı kombinasyonlarla test 5 kere tekrarlanmış (5-Katlı çapraz doğrulama) ve ortalaması alınmıştır. Bu, modelin sadece bir veri grubuna değil, tüm veri setine olan genelleme yeteneğini ölçmüş olmamızı sağlamıştır.

- Ortalama Doğruluk: %85.71 ( $\pm$  %6.02)
- Ortalama F1-Skoru: %85.56 ( $\pm$  %6.22)
- Pik Performans: Testlerin bir aşamasında %90.48 doğruluğa ulaşılmıştır.



Şekil 2: Pik performans konfüzyon matrisi

### 5.3 BOYUT İNDİRGEME VE PCA ETKİSİ

Çalışmanın son aşamasında, 25.088 boyutlu özellik uzayı üzerinde Temel Bileşen Analizi (PCA) uygulanmıştır.

- **Boyut İndirgeme:** PCA, özellik uzayını 25.088 boyuttan sadece **86 bileşene** (%95 varyans korunarak) indirgemıştır.
- **Performans Artışı:** Bu dramatik indirgemeye rağmen, sınıflandırma performansı artmış ve ortalama doğruluk 0.8571'den (tam özellikler) **0.8667**'ye (PCA özellikleri) yükselmiştir. F1-Skoru ise 0.8653 olarak kaydedilmiştir.
- **Bulgu:** Bu durum, orijinal yüksek boyutlu verinin PCA'nın etkili bir şekilde filtrelediği önemli miktarda fazlalık veya gürültü içerdiğini göstermektedir. Ayrıca sonuçlar, 25.000+ VGG16 özelliğinin büyük çoğunluğunun bu belirli sınıfları ayırt etmek için gereksiz olduğunu kanıtlamıştır.

6

## TARTIŞMA: NEDEN BAZI MODELLER DAHA ÜSTÜN?

### 6.1 RANDOM FOREST'İN K-NN ÜZERİNDEKİ ÜSTÜNLÜĞÜ

Analizlerimize göre Random Forest, K-NN'e göre daha başarılı olmuştur. Bunun sebepleri:

- **Boyutun Laneti (Curse of Dimensionality):** K-NN, 65 özellikli yüksek boyutlu uzayda komşuluk mesafelerini hesaplarken zorlanmakta; Random Forest ise özellik alt kümeleriyle çalışarak bu sorunu aşmaktadır.
- **Doğrusal Olmayan İlişkiler:** Parkinson verisindeki basınç ve hız arasındaki ilişki doğrusal değildir. Karar ağaçları bu karmaşık eşikleri çok daha iyi modellemektedir.

### 6.2 DERİN ÖĞRENMENİN (%85.7) GELENEKSEL YÖNTEMDEN (%75.8) FARKI

Görüntü işleme tabanlı derin özelliklerin, kinematik verilere göre yaklaşık %10 daha başarılı olmasının sebebi, spiral çizimlerdeki "mikro-tremor" (titreme) etkisinin görsel katmanlarda daha net temsil edilmesidir. Kinematik veriler sadece sayısal ortalamaları alırken, VGG16 çizimdeki her bir kıvrımı ve düzensizliği analiz etmektedir [SN25].

## SOTA İLE KARŞILAŞTIRMA

Mevcut projemiz başarılı sonuçlar üretse de, literatürdeki %95-%99 bandındaki skorlar (SOTA- State of the Art) ile aramızda bir fark bulunmaktadır. Bu farkın nedenleri şunlardır:

- **Özellik Eksikliği:** Literatürde kullanılan "Entropi" ve "Enerji" (SNR) tabanlı özellikler henüz modelimize dahil edilmemiştir [Dro15].
- **Hiperparametre Optimizasyonu:** Modellerimiz varsayılan ayarlarla çalışmıştır; Grid Search veya Bayesian Optimization ile bu oranlar artırılabilir.
- Bunun yanında geleneksel makine öğrenmesi modelleriyle yapılan çalışmalarda benzer doğruluk oranlarına ve F1-skorlarına ulaşıldığı görülmüştür.

## SONUÇ, KAZANIMLAR VE GELECEK ÇALIŞMALAR

**Sonuç:** Bu çalışma, PaHaW veri setiyle akıllı kalemde alınan verilerle makine öğrenmesi yapılmasının, ham görüntülerle görüntü işleme çalışmaktan çok daha başarısız olacağını bizlere göstermiştir. Ayrıca bu şekilde sadece akıllı kalemde alınan verilerle karşılaştırma yapıp teşhis yapılabilir. Kullanıcıdan spiral görüntüsü alınıp yorumlanamaz. Görüntü işleme yapılarak bu denli fark yaratılmasının sebebi ise transfer öğrenme yöntemi olarak VGG16 kullanılmasıdır. +14 milyon görsel içeren veri seti (imagenet), özellik çıkarmada bize çok fayda sağlamış, projemize kaldıraç etkisi yapmıştır.

**Kazanımlar:** En başta geleneksel makine öğrenmesi modellerinin çalışma prensipleri öğrenildi. Önceden anlamakta çok zorlandığım makaleler, jargona ve makine öğrenmesi sürecinde öğrendiklerime hakim olmamla nispeten kolay hale geldi. Python'da kullanılan kütüphanelerin ne işe yaradığı öğrenildi. Transfer learning; kullanarak, doğrudan deneyimleyerek öğrenildi. Daha önceden makine öğrenmesi çalışmış TAÜ bilgisayar mühendisliği öğrencileriyle bu konuları konuşabilecek düzeyde bilgi birikimine ulaşıldı.

### Gelecek Hedefler:

- **Boyut İndirgeme:** Boyut düşürme için PCA (Principle Component Analysis) uygulanınca model başarısının gerçekte neden düştüğü anlaşılacak.
- **Veri Artırma:** Mevcut 102 görsele ek veri toplanabilir.
- **El Yazısı Analizi:** El yazısından Parkinson hastalığı teşhisi yapan bir model oluşturulabilir ve bu modelde transfer öğrenme yoluyla bu projede yaptığımız modelden faydalanılabilir.
- **Derin Öğrenme:** Derin öğrenme kullanılarak bu analizler tekrarlanabilir.



**KAYNAKLAR**

- [Sino7] N. Singh, V. Pillay, and Y. E. Choonara, “Advances in the treatment of Parkinson’s disease. *Prog. Neurobiol.*, vol. 81, pp. 29–44, Jan. 2007.
- [BDA24] BDA Lab. PaHaW Dataset Repository. <https://github.com/BDALab>, 2024.
- [Madı8] K. Mader. Parkinson’s Drawings Dataset. <https://www.kaggle.com/datasets/kmader/parkinsons-drawings>, 2018.
- [Gup20] U. Gupta, H. Bansal ve D. Joshi. An improved sex-specific and age-dependent classification model for Parkinson’s diagnosis using handwriting measurement. *Computer Methods and Programs in Biomedicine*, 189:105305, 2020.
- [PK25] P. Pradeep ve J. Kamalakannan. Automated detection of Parkinson’s disease using improved LinkNet-GhostNet model based on handwriting images. *Scientific Reports*, 15(1):30731, 2025.
- [Dro15] P. Drotar ve ark. Decision Support Framework for Parkinson’s Disease Based on Novel Handwriting Markers. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 23(3):508–516, 2015.
- [Dro22] P. Drotar, J. Mekyska ve ark. Contribution of Different Handwriting Modalities to Differential Diagnosis of Parkinson’s Disease. *arXiv preprint arXiv:2203.11269*, 2022.
- [SN25] K. Shyamala ve T. M. Navamani. Design of a deep fusion model for early Parkinson’s disease prediction using handwritten image analysis. *Scientific Reports*, 15(1):20437, 2025.
- [Ian24] M. Ianculescu ve ark. Early Detection of Parkinson’s Disease Using AI Techniques and Image Analysis. *Diagnostics*, 14(23):2615, 2024.
- [Beco2] G. Becker ve ark. Early diagnosis of Parkinson’s disease. *Journal of Neurology*, 249:III/40–III/48, 2002.
- [Wan20] W. Wang ve ark. Early Detection of Parkinson’s Disease Using Deep Learning and Machine Learning. *IEEE Access*, 8:147635–147646, 2020.